

Proposta técnica e financeira

Assistente de voz e IA para o Drive Learn

Uma experiência do tipo “Fale comigo” para localizar treinamentos, explicar funções do veículo e responder dúvidas com base em conteúdo aprovado.

40	30	1.200	3 min
perguntas/dia por usuário	dias ativos/mês	interações/mês por usuário	duração média do vídeo

Conclusão executiva. É tecnicamente viável e o primeiro MVP pode operar com voz sem pagar síntese de áudio: a pergunta é transcrita pela API, a resposta é gerada por um modelo econômico e o navegador/celular lê o texto em voz alta. Com 50% de reaproveitamento do histórico, a estimativa de API é de R\$ 131,74 por usuário/mês.

Recomendação

Começar com um fluxo controlado: fontes aprovadas, respostas curtas, cache por pergunta e contexto, histórico completo, limite diário e aviso para uso com o veículo parado. A busca semântica e a validação administrativa podem ser ampliadas após medir as primeiras dúvidas reais.

Escopo desta estimativa

Custos de API apenas. Não inclui impostos, spread cambial, hospedagem, armazenamento, desenvolvimento, monitoramento ou atendimento humano. Cotação de referência: US\$ 1 = R\$ 5,13 em 28/07/2026. Preços devem ser confirmados antes da contratação.

1. Como a experiência funciona

Etapa	O que acontece	Como o custo é controlado
1. Pergunta	O usuário digita ou grava até 1 minuto.	Texto não exige transcrição; voz é transcrita uma única vez.
2. Reaproveitamento	A pergunta normalizada é comparada ao histórico e ao contexto atual.	Pergunta idêntica reutiliza automaticamente. Pergunta semelhante só reutiliza resposta validada.
3. Recuperação	O sistema localiza legendas, transcrições, vídeos publicados e especificações de modelos dentro do escopo do usuário.	Somente pequenos trechos relevantes seguem para o modelo.
4. Resposta	A IA recebe até 4.000 tokens e responde com até 800 tokens.	Modelo econômico, instrução de não inventar procedimentos e limite diário.
5. Voz e registro	O dispositivo lê a resposta e a interação fica registrada.	Síntese nativa do navegador evita cobrança de TTS no MVP.

Exemplo de diálogo

Motorista: “Estou com dificuldade de entender a função V constante no Meteor.”
Assistente: oferece explicar ou abrir o treinamento; a explicação usa apenas a transcrição aprovada daquele conteúdo e identifica o modelo quando necessário.

Regra de segurança

Se a fonte não for suficiente, a resposta deve declarar a limitação e direcionar ao vídeo ou à assistência técnica. O sistema não deve improvisar posições de botões, luzes do painel ou procedimentos operacionais.

2. Premissas e preços utilizados

Componente	Premissa	Preço unitário
Modelo de texto	GPT-5.6 Luna; 4.000 tokens de entrada e até 800 de saída	US\$ 1,00 / 1M entrada; US\$ 6,00 / 1M saída
Transcrição	GPT-Realtime-Whisper; áudio de até 1 minuto	US\$ 0,017 / minuto
Voz do MVP	Speech Synthesis do navegador/celular	Sem custo de API
Voz premium opcional	TTS-1; até cerca de 3.200 caracteres para 800 tokens	US\$ 15,00 / 1M caracteres
Uso mensal	40 perguntas/dia × 30 dias	1.200 interações por usuário

Custo máximo de uma pergunta inédita

Item	US\$	R\$
Texto — 4.000 tokens de entrada	0,0040	R\$ 0,02
Texto — 800 tokens de saída	0,0048	R\$ 0,02
Transcrição — 1 minuto	0,0170	R\$ 0,09
Total MVP com voz nativa	0.0258	R\$ 0,13
TTS premium opcional	0.0480	R\$ 0,25
Total com TTS premium	0.0738	R\$ 0,38

Conservadorismo: a conta considera o áudio sempre com 1 minuto e a resposta sempre no teto de 800 tokens. Na prática, respostas curtas tendem a reduzir o gasto.

3. Estimativa mensal — MVP recomendado

Cenário-base: 50% das perguntas reaproveitam uma resposta já armazenada. Perguntas de voz ainda passam pela transcrição; a geração do texto é evitada no cache. Voz de saída é feita pelo dispositivo.

Usuários ativos	Perguntas/mês	Custo de API (US\$)	Estimativa em reais
10	12.000	US\$ 256,80	R\$ 1.317,38
25	30.000	US\$ 642,00	R\$ 3.293,46
50	60.000	US\$ 1.284,00	R\$ 6.586,92
75	90.000	US\$ 1.926,00	R\$ 9.880,38
100	120.000	US\$ 2.568,00	R\$ 13.173,84

Sensibilidade ao reaproveitamento

Cache	Custo por usuário/mês	100 usuários/mês	Leitura
0%	R\$ 158,82	R\$ 15.882,48	Tudo é resposta nova
30%	R\$ 142,57	R\$ 14.257,30	Mais respostas reutilizadas
50%	R\$ 131,74	R\$ 13.173,84	Mais respostas reutilizadas
70%	R\$ 120,90	R\$ 12.090,38	Mais respostas reutilizadas

Comparativo com voz premium

No mesmo cenário de 50% de cache, com TTS pago em todas as respostas inéditas e o teto de 800 tokens, o custo pode chegar a **R\$ 279,48 por usuário/mês** ou **R\$ 27.948,24 para 100 usuários**. Por isso, a voz nativa do dispositivo é a escolha recomendada para o MVP.

Se a intenção era 40 perguntas por usuário **por mês**, e não por dia, os valores de uso caem aproximadamente 30 vezes.

4. Tratamento dos vídeos

A IA não precisa assistir ao vídeo em toda pergunta. Cada conteúdo deve ser preparado uma vez e convertido em conhecimento consultável.

Origem	Processamento recomendado	Custo estimado por vídeo de 3 min
YouTube com legenda	Importar e revisar a legenda; gerar um resumo estruturado.	R\$ 0,05
Arquivo local com áudio	Transcrever 3 minutos; revisar; gerar resumo estruturado.	R\$ 0,31
Vídeo já transcrito	Salvar texto aprovado; nenhuma nova transcrição.	Próximo de zero

Exemplo de lote

Em um acervo de 100 vídeos, metade com legenda pronta e metade exigindo transcrição de 3 minutos, o processamento inicial é estimado em aproximadamente R\$ 17,60. É um custo pontual; as perguntas posteriores consultam o texto armazenado.

Qualidade da fonte

Antes da publicação, um responsável deve revisar nomes de funções, versões, localização de comandos e avisos. Legendas automáticas podem confundir siglas técnicas. A resposta precisa guardar a origem — vídeo, modelo e versão — para auditoria.

Vídeos sem transcrição

O MVP permite colar a legenda do YouTube ou a transcrição de um vídeo local no cadastro. Uma etapa posterior pode automatizar a extração e criar uma fila de revisão administrativa.

5. Dados, cache e governança

Controle	Comportamento proposto
Histórico individual	Guardar pergunta, resposta, usuário, empresa, origem, tokens, duração do áudio, custo estimado, latência e data.
Cache exato	Reutilização automática quando pergunta e contexto permanecem iguais.
Semelhança	Reutilização somente de respostas previamente validadas e com alta similaridade; caso contrário, gerar nova resposta.
Escopo	Respeitar as marcas, modelos, vídeos publicados e permissões visíveis ao usuário.
Atualização	Mudança na fonte altera o hash de contexto e impede o uso silencioso de uma resposta antiga.
Privacidade	Não enviar senhas, CPF/CNPJ, dados pessoais desnecessários ou conteúdo fora do escopo técnico.
Retenção	Definir prazo para áudio bruto; preferencialmente descartá-lo após a transcrição e manter somente texto e metadados.

Indicadores recomendados

Perguntas por usuário, percentual de cache, custo por empresa, dúvidas sem resposta, vídeos mais citados, avaliações das respostas, tempo médio e taxa de encaminhamento à assistência.

Ponto de atenção

Uma resposta gerada não deve tornar-se conhecimento confiável apenas por existir no histórico. A reutilização por similaridade deve depender de validação; perguntas idênticas podem usar cache contextual para eficiência.

6. Arquitetura implementada no MVP

Camada	Entregue nesta versão
Interface	Botão “Fale comigo :)”, painel responsivo, digitação, gravação de até 60 segundos e leitura pelo dispositivo.
Fontes	Vídeos publicados com descrição/legenda/transcrição e especificações dos modelos acessíveis ao usuário.
OpenAI	Transcrição de áudio e geração de resposta via Responses API; modelos configuráveis por ambiente.
Persistência	Base de respostas reutilizáveis e log completo de interações e custos estimados.
Proteções	CSRF, permissão da biblioteca, limite diário de 40 perguntas, tamanho de áudio e resposta fundamentada.
Cadastro de vídeo	Campo para legenda ou transcrição revisada, utilizado como fonte prioritária.

Próximos passos antes da produção

1. Executar a migration na HostGator.
2. Criar o arquivo **.env.ai** no servidor, fora do controle de versão, com a chave da API.
3. Preencher e revisar transcrições dos vídeos prioritários.
4. Testar permissões por empresa e marca.
5. Definir retenção, moderação e responsável pela validação de respostas.
6. Acompanhar o custo real por 30 dias e ajustar limites.

Fase seguinte sugerida

Adicionar painel de curadoria para aprovar respostas, fila automática de transcrição de arquivos locais, busca vetorial/semântica, feedback “ajudou/não ajudou” e abertura direta do vídeo no ponto relevante.

7. Fontes e observações finais

Documentação oficial OpenAI

Preços da API: <https://openai.com/api/pricing/>

Guia de áudio e fala: <https://platform.openai.com/docs/guides/audio>

Responses API: <https://platform.openai.com/docs/api-reference/responses>

Os preços utilizados nesta análise foram consultados em 28/07/2026. A OpenAI pode alterar modelos, nomenclaturas e tarifas. O valor em reais oscila com o câmbio, IOF e cobrança do meio de pagamento.

Decisão recomendada

Aprovar um piloto com até 10 usuários e conteúdo de maior recorrência. Manter a saída por voz do dispositivo, respostas curtas, 40 perguntas/dia como teto e cache validado. Após 30 dias, recalcular a média real de tokens, duração do áudio e percentual de reaproveitamento antes de ampliar a base.

Preparado para Drive Learn

Lucas Paiva · Lux Solution